

UNIVERSIDAD TÉCNICA PARTICULAR DE LOJA

Carrera de Computación

Agentes de Inteligencia Artificial

LLM, Razonamiento, Tool Use y RAG
Frameworks, Evaluación y Sistemas Inteligentes

Investigación Académica

Estudiante: Bryan Michael Villa Camacho

Asignatura: Practicum 1.2

Carrera: Computación

Fecha: 8 de mayo de 2026

Índice

1. Resumen	2
2. Introducción	2
3. Marco conceptual	3
3.1. Agentes de Inteligencia Artificial	3
3.2. Large Language Models (LLM)	3
3.3. Razonamiento en agentes	4
3.3.1. Chain of Thought	4
3.3.2. ReAct	4
3.3.3. Tree of Thoughts	4
3.3.4. Self-Reflection	4
3.4. Tool Use y Function Calling	5
3.5. Retrieval-Augmented Generation (RAG)	5
3.6. Evaluación de agentes	6
4. Trabajos relacionados	6
4.1. Investigaciones académicas	6
4.2. Casos de industria y universidades	7
5. Herramientas y tecnologías	8
5.1. LangChain	8
5.2. LangGraph	8
5.3. LlamaIndex	8
5.4. OpenAI Agents SDK	9
5.5. Pinecone	9
6. Tendencias y futuro	9
7. Conclusiones	10
8. Referencias	10

1. Resumen

Los agentes de Inteligencia Artificial representan una evolución significativa dentro de los sistemas basados en modelos de lenguaje de gran escala (LLM). A diferencia de los chatbots convencionales, estos agentes integran razonamiento, planificación, memoria contextual y uso de herramientas externas para ejecutar tareas complejas de forma autónoma. Arquitecturas como Retrieval-Augmented Generation (RAG), Chain of Thought y ReAct permiten mejorar la precisión, reducir las alucinaciones y ampliar las capacidades operativas de los modelos de lenguaje. Asimismo, frameworks modernos como LangChain, LangGraph y LlamaIndex facilitan el desarrollo de aplicaciones inteligentes capaces de interactuar con documentos, APIs, bases de datos y motores de búsqueda vectorial. La evaluación de estos sistemas constituye un desafío relevante debido a problemas relacionados con la precisión factual, la trazabilidad y la calidad del razonamiento. El presente trabajo analiza los conceptos fundamentales, los frameworks, las tecnologías, las investigaciones recientes y las tendencias futuras vinculadas con los agentes de Inteligencia Artificial en el área de Ciencias de la Computación.

2. Introducción

La Inteligencia Artificial ha experimentado un crecimiento acelerado gracias al desarrollo de los Large Language Models (LLM), modelos capaces de comprender y generar lenguaje natural mediante arquitecturas Transformer. Sistemas como GPT, Claude y Llama han demostrado capacidades avanzadas en razonamiento, generación de texto y resolución de problemas complejos [1].

Sin embargo, los modelos tradicionales presentan limitaciones importantes relacionadas con la memoria persistente, el razonamiento estructurado y el acceso a información actualizada. Para superar dichas limitaciones surgieron los agentes de Inteligencia Artificial, que integran razonamiento, memoria, planificación y utilización de herramientas externas con el fin de ejecutar acciones de forma autónoma [5].

En este contexto, arquitecturas como Retrieval-Augmented Generation (RAG) permiten complementar el conocimiento interno del modelo mediante la recuperación de información desde bases externas, lo que reduce las alucinaciones y mejora la precisión de las respuestas [2].

Actualmente, los agentes inteligentes se emplean en asistentes empresariales, sistemas educativos, automatización documental, recuperación de información y análisis de datos. Asimismo, frameworks modernos facilitan el desarrollo de aplicaciones agentivas capaces de utilizar APIs, motores de búsqueda y bases vectoriales.

El objetivo de esta investigación es analizar los fundamentos conceptuales, los frameworks, los métodos de evaluación y las tendencias futuras de los agentes de Inteligencia Artificial.

3. Marco conceptual

3.1. Agentes de Inteligencia Artificial

Un agente de Inteligencia Artificial es un sistema capaz de percibir información, razonar sobre ella y ejecutar acciones orientadas a cumplir objetivos específicos. A diferencia de un chatbot convencional, un agente inteligente puede planificar tareas, utilizar herramientas externas y adaptar sus acciones según el contexto.

Los agentes modernos generalmente integran:

- Modelos de lenguaje grandes (LLM)
- Memoria contextual
- Sistemas de razonamiento
- Planificación multi-paso
- Herramientas externas

Russell y Norvig (2021) describen a los agentes inteligentes como sistemas racionales capaces de percibir el entorno y ejecutar acciones orientadas a maximizar resultados [3].

3.2. Large Language Models (LLM)

Los Large Language Models son redes neuronales entrenadas sobre grandes volúmenes de datos textuales para predecir secuencias lingüísticas. Estos modelos utilizan arquitecturas Transformer para procesar información contextual y generar respuestas coherentes.

Entre los conceptos técnicos más importantes se encuentran los tokens, los embeddings, la ventana de contexto, la temperatura y el mecanismo de atención. Los embeddings representan información semántica mediante vectores numéricos, lo que permite búsquedas semánticas y recuperación contextual de información.

Brown et al. (2020) demostraron que los modelos de gran escala pueden resolver múltiples tareas utilizando aprendizaje contextual sin necesidad de entrenamiento específico para cada problema [1].

3.3. Razonamiento en agentes

Los agentes modernos utilizan diferentes técnicas de razonamiento para resolver problemas complejos y mejorar la toma de decisiones.

3.3.1. Chain of Thought

La técnica de Chain of Thought Prompting permite que el modelo genere un razonamiento paso a paso antes de producir una respuesta final. Esta técnica mejora significativamente el desempeño en tareas matemáticas, lógicas y analíticas [4].

3.3.2. ReAct

ReAct combina razonamiento y ejecución de acciones mediante herramientas externas. El agente razona sobre un problema, ejecuta acciones y posteriormente continúa el razonamiento utilizando la información obtenida [5].

3.3.3. Tree of Thoughts

Tree of Thoughts permite explorar múltiples rutas de razonamiento simultáneamente antes de seleccionar la mejor solución posible [6].

3.3.4. Self-Reflection

Algunos agentes incorporan mecanismos de autoevaluación capaces de revisar, corregir y optimizar respuestas antes de entregarlas al usuario final.

3.4. Tool Use y Function Calling

El Tool Use permite que un modelo de lenguaje interactúe con APIs, motores de búsqueda, bases de datos y herramientas externas.

El flujo general incluye:

1. Interpretación de la solicitud
2. Selección de herramienta
3. Ejecución de acción
4. Obtención de resultados
5. Integración al razonamiento

La documentación oficial del OpenAI Agents SDK establece que los agentes modernos pueden coordinar múltiples herramientas dentro de flujos complejos de trabajo [12].

3.5. Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) combina recuperación de información y generación de lenguaje natural. El sistema primero recupera información relevante desde una fuente externa y posteriormente utiliza esa información como contexto para generar respuestas más precisas [2].

El flujo de trabajo general incluye:

1. Conversión de consultas en embeddings
2. Búsqueda semántica
3. Recuperación de documentos
4. Generación contextualizada

Las bases vectoriales más utilizadas incluyen Pinecone, Weaviate, Chroma, Milvus y pgvector. Los sistemas RAG reducen las alucinaciones y mejoran la precisión factual en aplicaciones especializadas.

3.6. Evaluación de agentes

La evaluación de agentes inteligentes es compleja debido a la interacción entre razonamiento, memoria y herramientas externas.

Las métricas más utilizadas incluyen:

- Precisión
- Recall
- Faithfulness
- Latencia
- Exactitud de herramientas
- Goal Completion Rate

Frameworks como LangSmith y Phoenix permiten analizar trazabilidad, errores y desempeño de agentes en producción.

4. Trabajos relacionados

4.1. Investigaciones académicas

Diversas investigaciones recientes han explorado arquitecturas agentivas basadas en modelos de lenguaje:

- Yao et al. (2023) propusieron ReAct, arquitectura que integra razonamiento y ejecución de acciones mediante interacción con herramientas externas [5].
- Wei et al. (2022) demostraron que Chain of Thought mejora considerablemente el desempeño de modelos de lenguaje en problemas complejos mediante razonamiento paso a paso [4].
- Lewis et al. (2020) introdujeron Retrieval-Augmented Generation (RAG), arquitectura ampliamente utilizada actualmente en asistentes documentales, sistemas empresariales y recuperación contextual de información [2].

- Rawat et al. (2025) desarrollaron Pre-Act, enfoque basado en planificación multi-paso para agentes autónomos. Los autores reportaron mejoras importantes en métricas relacionadas con razonamiento y ejecución de acciones [7].
- Ru et al. (2024) propusieron RAGCHECKER, framework orientado a evaluación detallada de sistemas Retrieval-Augmented Generation mediante métricas de recuperación y generación contextual [8].

4.2. Casos de industria y universidades

Actualmente, diversas empresas tecnológicas y universidades utilizan arquitecturas basadas en agentes inteligentes y modelos LLM en aplicaciones reales:

- Microsoft incorporó agentes inteligentes en Microsoft Copilot para generación de documentos, análisis de datos y automatización de tareas mediante integración con herramientas de Office.
- OpenAI desarrolló el OpenAI Agents SDK, plataforma orientada a agentes capaces de utilizar herramientas externas, navegación web y ejecución de funciones.
- Google investiga sistemas multimodales y arquitecturas agentivas aplicadas a búsqueda inteligente y automatización.
- Stanford University y Massachusetts Institute of Technology (MIT) investigan arquitecturas multiagente, razonamiento autónomo y evaluación de confiabilidad en modelos de lenguaje.
- Diversos laboratorios universitarios utilizan sistemas Retrieval-Augmented Generation (RAG) en asistentes educativos, recuperación documental y búsqueda semántica sobre artículos científicos y materiales académicos.

5. Herramientas y tecnologías

5.1. LangChain

LangChain es uno de los frameworks más utilizados para construir aplicaciones basadas en modelos de lenguaje y sistemas agentivos. Proporciona integración con modelos LLM, herramientas externas, bases vectoriales y memoria conversacional [9].

Entre sus principales ventajas se encuentran su arquitectura modular, la integración con múltiples proveedores LLM, el soporte para agentes inteligentes, la integración con herramientas externas y el manejo de memoria contextual.

5.2. LangGraph

LangGraph es un framework orientado a la construcción de flujos basados en grafos de estados para arquitecturas multiagente [10].

Este framework facilita modelar procesos complejos mediante nodos y transiciones dinámicas entre agentes especializados. Su arquitectura permite representar ciclos, decisiones condicionales y coordinación entre múltiples agentes dentro de un mismo flujo de trabajo. LangGraph se integra de manera nativa con LangChain y sistemas de memoria contextual.

5.3. LlamaIndex

LlamaIndex es un framework orientado al desarrollo de aplicaciones basadas en modelos de lenguaje y arquitecturas Retrieval-Augmented Generation (RAG). Su principal objetivo es facilitar la integración entre modelos LLM y fuentes externas de información mediante procesos de ingestión, indexación y recuperación semántica de datos [11].

El framework permite trabajar con documentos estructurados y no estructurados, incluyendo archivos PDF, bases de datos, APIs y contenido empresarial. Además, proporciona herramientas para la construcción de índices vectoriales, motores de consulta y agentes inteligentes capaces de utilizar información contextualizada durante la generación de respuestas.

5.4. OpenAI Agents SDK

El OpenAI Agents SDK es un conjunto de herramientas orientado al desarrollo de agentes inteligentes capaces de utilizar herramientas externas, ejecutar funciones y coordinar flujos complejos de trabajo [12].

Este SDK facilita la creación de aplicaciones agentivas mediante integración con modelos de lenguaje, manejo de memoria contextual, uso de herramientas y sistemas de trazabilidad. Además, permite registrar eventos relacionados con llamadas al modelo, ejecución de herramientas y procesos de razonamiento. La plataforma incorpora mecanismos de tracing y monitoreo que permiten analizar el comportamiento interno de los agentes durante la ejecución, facilitando tareas de depuración y evaluación de desempeño.

5.5. Pinecone

Pinecone es una base de datos vectorial especializada en almacenamiento y recuperación semántica de embeddings dentro de sistemas Retrieval-Augmented Generation (RAG) [13].

Su principal función es permitir búsquedas vectoriales de alta eficiencia mediante comparación semántica entre consultas y documentos previamente indexados. Esto facilita la recuperación contextual de información en aplicaciones basadas en modelos de lenguaje. Entre sus principales ventajas se encuentran la escalabilidad, la baja latencia y la capacidad de integración con frameworks modernos como LangChain y LlamaIndex.

6. Tendencias y futuro

Durante los próximos años se espera una evolución importante hacia agentes más autónomos, multimodales y colaborativos.

Las principales tendencias incluyen:

- Arquitecturas multiagente
- Agentes multimodales
- Memoria persistente

- RAG multimodal
- Evaluación automática mediante LLM-as-a-judge
- Agentes capaces de navegar y operar en entornos web

Asimismo, las investigaciones actuales buscan reducir las alucinaciones y mejorar el razonamiento mediante planificación explícita, verificación automática y modelos híbridos. Empresas tecnológicas y universidades están investigando sistemas capaces de coordinar múltiples agentes especializados para resolver tareas complejas de forma distribuida.

7. Conclusiones

Los agentes de Inteligencia Artificial constituyen una de las áreas más relevantes dentro de la computación moderna. La combinación de LLM, razonamiento, Tool Use y arquitecturas RAG ha permitido desarrollar sistemas capaces de resolver tareas complejas de manera autónoma.

Frameworks como LangChain, LangGraph y LlamaIndex facilitan el desarrollo de aplicaciones inteligentes en ámbitos empresariales, educativos y científicos. Asimismo, las técnicas modernas de razonamiento permiten mejorar la precisión y la calidad de las respuestas en tareas complejas.

La evaluación y la trazabilidad se han convertido en aspectos fundamentales debido a problemas relacionados con alucinaciones, errores de razonamiento y utilización incorrecta de herramientas externas.

Finalmente, las tendencias actuales apuntan hacia arquitecturas multiagente, agentes multimodales y sistemas con mayor autonomía, lo que probablemente transformará múltiples áreas de la informática durante los próximos años.

8. Referencias

Referencias

- [1] Brown, T. et al. *Language Models are Few-Shot Learners*. NeurIPS, 2020.

- [2] Lewis, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS, 2020.
- [3] Russell, S. and Norvig, P. *Artificial Intelligence: A Modern Approach*. Pearson, 2021.
- [4] Wei, J. et al. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.
- [5] Yao, S. et al. *ReAct: Synergizing Reasoning and Acting in Language Models*. ICLR, 2023.
- [6] Yao, S. et al. *Tree of Thoughts: Deliberate Problem Solving with Large Language Models*. arXiv, 2023.
- [7] Rawat, M. et al. *Pre-Act: Multi-Step Planning and Reasoning Improves Acting in LLM Agents*. arXiv, 2025.
- [8] Ru, D. et al. *RAGCHECKER: A Fine-grained Framework for Diagnosing Retrieval-Augmented Generation*. arXiv, 2024.
- [9] LangChain. *LangChain Documentation*.
Disponible en: <https://docs.langchain.com/>
- [10] LangGraph. *LangGraph Documentation*.
Disponible en: <https://docs.langchain.com/langgraph>
- [11] LlamaIndex. *LlamaIndex Documentation*.
Disponible en: <https://docs.llamaindex.ai/>
- [12] OpenAI. *OpenAI Agents SDK Documentation*.
Disponible en: <https://platform.openai.com/docs/guides/agents>
- [13] Pinecone. *Pinecone Documentation*.
Disponible en: <https://docs.pinecone.io/>